

YouTube Analytics – Data Product & ML Prediction

Partie 1 : Compréhension des données (Data Understanding)

Fatoumata Diallo

August 1, 2026

1 Aggregated_Metrics_By_Country_And_Subscriber_Status

Objet du fichier : performance de chaque vidéo, ventilée par pays et par statut d'abonnement du spectateur (abonné vs non-abonné). Permet d'analyser où et auprès de qui une vidéo performe.

Colonne	Signification
Video Title	Titre de la vidéo
External Video ID	Identifiant unique YouTube de la vidéo
Video Length	Durée de la vidéo (en secondes)
Thumbnail link	URL de la miniature de la vidéo
Country Code	Code pays (ISO) du spectateur
Is Subscribed	Indique si le spectateur était abonné à la chaîne au moment du visionnage (Vrai/Faux)
Views	Nombre de vues pour cette combinaison vidéo/pays/statut
Video Likes Added	Nombre de “likes” ajoutés
Video Dislikes Added	Nombre de “dislikes” ajoutés
Video Likes Removed	Nombre de “likes” retirés
User Subscriptions Added	Nombre de nouveaux abonnés générés par cette vidéo
User Subscriptions Removed	Nombre de désabonnements liés à cette vidéo
Average View Percentage	Pourcentage moyen de la vidéo visionné (peut dépasser 100% pour les Shorts visionnés en boucle)
Average Watch Time	Durée moyenne de visionnage (en secondes)
User Comments Added	Nombre de commentaires ajoutés

2 Aggregated_Metrics_By_Video

Objet du fichier : vue synthétique et globale de chaque vidéo (tous pays et tous statuts confondus), incluant des indicateurs de monétisation absents des autres fichiers.

Colonne	Signification
Video	Identifiant unique de la vidéo
Video title	Titre de la vidéo
Video publish time	Date de publication de la vidéo
Comments added	Nombre total de commentaires reçus
Shares	Nombre de partages
Dislikes	Nombre total de “dislikes”
Likes	Nombre total de “likes”
Subscribers lost	Nombre d'abonnés perdus liés à la vidéo

Colonne	Signification
Subscribers gained	Nombre de nouveaux abonnés liés à la vidéo
RPM (USD)	Revenu pour mille vues (Revenue per Mille), indicateur de monétisation
CPM (USD)	Coût pour mille impressions publicitaires (Cost per Mille)
Average percentage viewed (%)	Pourcentage moyen de la vidéo visionné
Average view duration	Durée moyenne de visionnage (format temporel hh:mm:ss)
Views	Nombre total de vues
Watch time (hours)	Temps total de visionnage cumulé (en heures)
Subscribers	Solde net d'abonnés (gagnés – perdus) lié à la vidéo
Your estimated revenue (USD)	Revenu estimé généré par la vidéo
Impressions	Nombre de fois où la miniature de la vidéo a été affichée aux utilisateurs
Impressions click-through rate (%)	Taux de clic sur la miniature (impressions → vue)

Remarque : la première ligne de ce fichier correspond à un total agrégé (“Total”), et non à une vidéo – ce n’est pas une colonne mais une observation particulière à distinguer des autres lignes.

3 All_Comments_Final

Objet du fichier : ensemble des commentaires publiés sur les vidéos de la chaîne, avec leurs métadonnées d’engagement.

Colonne	Signification
Comments	Contenu textuel du commentaire
Comment_ID	Identifiant unique du commentaire
Reply_Count	Nombre de réponses reçues par ce commentaire
Like_Count	Nombre de “likes” reçus par ce commentaire
Date	Date et heure de publication du commentaire
VidId	Identifiant de la vidéo sur laquelle le commentaire a été posté
user_ID	Identifiant anonymisé de l'utilisateur ayant posté le commentaire

4 Video_Performance_Over_Time

Objet du fichier : évolution jour par jour des performances de chaque vidéo (tous pays et statuts confondus), depuis sa publication. C’est la table de référence pour toute analyse ou modélisation temporelle.

Colonne	Signification
Date	Date d’observation de la mesure
Video Title	Titre de la vidéo
External Video ID	Identifiant unique YouTube de la vidéo
Video Length	Durée de la vidéo (en secondes)

Colonne	Signification
Thumbnail link	URL de la miniature de la vidéo
Views	Nombre de vues enregistrées ce jour-là
Video Likes Added	Nombre de “likes” ajoutés ce jour-là
Video Dislikes Added	Nombre de “dislikes” ajoutés ce jour-là
Video Likes Removed	Nombre de “likes” retirés ce jour-là
User Subscriptions Added	Nouveaux abonnés générés ce jour-là
User Subscriptions Re- moved	Désabonnements survenus ce jour-là
Average View Percentage	Pourcentage moyen de la vidéo visionné ce jour-là
Average Watch Time	Durée moyenne de visionnage ce jour-là (en secondes)
User Comments Added	Nombre de commentaires ajoutés ce jour-là

5 Clés de jointure entre les fichiers

Fichier	Colonne identifiant la vidéo
Aggregated_Metrics_By_Country_And_ExternalVideoID	ExternalVideoID
Aggregated_Metrics_By_Video	Video
All_Comments_Final	VidId
Video_Performance_Over_Time	External Video ID

Table 5: Les quatre fichiers partagent le même identifiant vidéo YouTube, sous des noms de colonnes différents.

6 Remarques de qualité à retenir

- Ligne “Total” dans **Aggregated_Metrics_By_Video** à exclure des analyses
- Caractères invisibles dans les en-têtes de colonnes de **Aggregated_Metrics_By_Video** (soft hyphens) à nettoyer
- Espaces parasites sur certains **Video ID**
- Formats de date hétérogènes selon les fichiers ("May 8, 2020", "19 Jan 2022", avec parfois "Sept" au lieu de "Sep")
- **Average View Percentage** peut dépasser 100% pour les vidéos courtes (Shorts) visionnées en boucle – comportement normal, pas une erreur