

YouTube Analytics – Data Product & ML Prediction

Fatoumata Diallo

August 19, 2026

Contents

1	Introduction et objectif	2
2	Compréhension des données	2
2.1	Aggregated_Metrics_By_Country_And_Subscriber_Status	2
2.2	Aggregated_Metrics_By_Video	2
2.3	All_Comments_Final	3
2.4	Video_Performance_Over_Time	3
3	Nettoyage des données	3
4	Analyse exploratoire (EDA)	3
5	Préparation du dataset (feature engineering)	3
6	Modélisation	4
6.1	Version 1 – avec fuite de données	4
6.2	Version 2 – corrigée, sans fuite de données	4
7	Résultats et interprétation	4
8	Limites et pistes d’amélioration	4
9	Conclusion	5

1 Introduction et objectif

Ce projet vise à prédire la performance (nombre de vues) d'une vidéo YouTube à partir de ses caractéristiques et de sa performance durant les 7 premiers jours suivant sa publication. L'objectif est de fournir un outil d'aide à la décision pour anticiper le potentiel d'une vidéo tôt dans son cycle de vie.

Quatre sources de données ont été utilisées, cohérentes sur 223 vidéos uniques.

2 Compréhension des données

2.1 Aggregated_Metrics_By_Country_And_Subscriber_Status

Performance de chaque vidéo, ventilée par pays et par statut d'abonnement du spectateur (abonné vs non-abonné).

Colonne	Signification
Video Title	Titre de la vidéo
External Video ID	Identifiant unique YouTube de la vidéo
Video Length	Durée de la vidéo (secondes)
Country Code	Code pays (ISO) du spectateur
Is Subscribed	Le spectateur était-il abonné (Vrai/Faux)
Views	Nombre de vues pour cette combinaison vidéo/pays/statut
Video Likes/Dislikes Added/Removed	Variations de likes/dislikes
User Subscriptions Added/Removed	Abonnements gagnés/perdus
Average View Percentage	% moyen de la vidéo visionné (peut dépasser 100% pour les Shorts)
Average Watch Time	Durée moyenne de visionnage (secondes)
User Comments Added	Commentaires ajoutés

2.2 Aggregated_Metrics_By_Video

Vue synthétique globale de chaque vidéo (tous pays/statuts confondus), incluant les indicateurs de monétisation.

Colonne	Signification
Video / Video title	Identifiant et titre de la vidéo
Video publish time	Date de publication
Comments added, Shares, Likes, Dislikes	Indicateurs d'engagement globaux
Subscribers gained/lost	Abonnés gagnés/perdus liés à la vidéo
RPM (USD), CPM (USD)	Indicateurs de monétisation
Average percentage viewed (%)	% moyen visionné
Views, Watch time (hours)	Vues et temps de visionnage cumulés
Your estimated revenue (USD)	Revenu estimé
Impressions, CTR (%)	Affichages de la miniature et taux de clic

Remarque : la première ligne ("Total") est un agrégat global, exclue des analyses.

2.3 All_Comments_Final

Ensemble des commentaires publiés sur les vidéos.

Colonne	Signification
Comments	Contenu textuel du commentaire
Comment_ID	Identifiant unique du commentaire
Reply_Count, Like_Count	Engagement du commentaire
Date	Date de publication du commentaire
VidId	Identifiant de la vidéo liée
user_ID	Identifiant anonymisé de l'auteur

2.4 Video_Performance_Over_Time

Évolution jour par jour des performances de chaque vidéo depuis sa publication – table de référence pour l'analyse temporelle et la construction des variables précoces (J+7).

3 Nettoyage des données

- Suppression de la ligne "Total" (agrégat) dans **Aggregated_Metrics_By_Video**
- Suppression des caractères invisibles (soft hyphens) dans les noms de colonnes
- Suppression des espaces parasites en début d'identifiant vidéo
- Harmonisation des formats de date ("Sept" → "Sep", formats explicites %b %d, %Y)

4 Analyse exploratoire (EDA)

- **Distribution des vues** : très asymétrique (loi de puissance), justifiant une transformation logarithmique de la cible
- **Top vidéos** : un petit nombre de vidéos concentre l'essentiel des vues de la chaîne
- **Corrélations** : Views, Watch time, Likes et Comments added sont fortement corrélés entre eux ; Average percentage viewed (%) est plus indépendant, reflétant une dimension qualité/rétention distincte du volume
- **Abonnés vs non-abonnés** : les abonnés regardent en moyenne une part plus importante de la vidéo et plus longtemps, mais génèrent moins de vues en volume total (la chaîne touchant davantage de non-abonnés)

5 Préparation du dataset (feature engineering)

Dataset final : **222 vidéos** × 16 variables. Variables construites :

- Métadonnées de publication : jour de la semaine, mois, année
- video_length : durée de la vidéo
- n_countries : nombre de pays ayant généré des vues
- subscribed_share : part des vues issues d'abonnés
- views_7d, likes_7d, comments_7d, avg_view_pct_7d : performance cumulée sur les 7 premiers jours

- `n_comments_total` : volume total de commentaires reçus

Cible : $\log(\text{Views} + 1)$, afin de stabiliser la variance liée à la distribution asymétrique des vues.

6 Modélisation

Deux modèles ont été testés (régression linéaire et Random Forest), sur un split train/test 80/20.

6.1 Version 1 – avec fuite de données

Toutes les variables sont incluses, y compris `n_countries` et `n_comments_total`, qui sont calculées sur l'ensemble de la vie de la vidéo (donc corrélées quasi-directement à la cible).

	Régression linéaire	Random Forest
MAE	0.246	0.240
RMSE	0.309	0.312
R ²	0.928	0.926

Table 4: Résultats Version 1

Importance des variables (Random Forest) : `n_countries` domine à 87,9%, suivie de `n_comments_total` (7,8%). Ce résultat, bien que statistiquement très élevé, n'est **pas exploitable** pour un cas d'usage prédictif réel : ces variables ne sont pas disponibles tôt dans le cycle de vie d'une vidéo et reflètent en grande partie la cible elle-même.

6.2 Version 2 – corrigée, sans fuite de données

Seules les variables disponibles à J+7 sont conservées : `video_length`, `pub_dow`, `pub_month`, `subscribed_share`, `views_7d`, `likes_7d`, `comments_7d`, `avg_view_pct_7d`.

	Régression linéaire	Random Forest
MAE	0.687	0.456
RMSE	0.881	0.696
R ²	0.413	0.634

Table 5: Résultats Version 2 (modèle retenu)

Importance des variables (Random Forest) : `subscribed_share` (43,4%), `views_7d` (20,6%), `likes_7d` (18,2%), `video_length` (7,7%), `avg_view_pct_7d` (6,0%).

7 Résultats et interprétation

Le modèle Random Forest Version 2 est retenu comme modèle final : **R² = 0,634**, soit environ 63% de la variance du nombre de vues expliquée à partir des seules 7 premières journées suivant la publication.

Les variables les plus prédictives sont la part de vues issue des abonnés et la performance précoce en vues/likes, ce qui est cohérent avec le fonctionnement de l'algorithme de recommandation YouTube : une vidéo bien reçue très tôt par l'audience existante tend à être davantage recommandée ensuite.

8 Limites et pistes d'amélioration

- Échantillon limité (222 vidéos) → risque de surapprentissage, résultats à confirmer sur un plus grand volume

- Tuning des hyperparamètres (`GridSearchCV`) non encore réalisé
- Validation croisée à mettre en place pour un score plus robuste
- Ajout de variables sur le sentiment des commentaires (analyse NLP)
- Approche série temporelle pure envisageable (prédiction jour par jour plutôt qu'agrégée à J+7)

9 Conclusion

Ce projet illustre l'importance de la vigilance face aux fuites de données en modélisation prédictive : un premier modèle affichant un R^2 de 0,93 s'est révélé non exploitable une fois les variables biaisées retirées. Le modèle final, plus modeste ($R^2=0,63$) mais méthodologiquement valide, constitue une base solide pour un outil de prédiction précoce de performance vidéo.